

# 一、 Spark 集群安装

### 1. 安装

### 1.1. 机器部署

准备两台以上 Linux 服务器,并安装好 JDK。

### 1.2. 下载 Spark 安装包

## **Download Spark**

The latest release of Spark is Spark 1.5.2, released on November 9, 2015 (release notes) (git tag)

- 1. Choose a Spark release: 1.5.2 (Nov 09 2015) ▼
- 2. Choose a package type: Pre-built for Hadoop 2.6 and later
- 3. Choose a download type: Select Apache Mirror ▼
- 4. Download Spark: spark-1.5.2-bin-hadoop2.6.tgz

选择预编译对应的Hadoop版本

5. Verify this release using the 1.5.2 signatures and checksums.

Note: Scala 2.11 users should download the Spark source package and build with Scala 2.11 support.

http://www.apache.org/dyn/closer.lua/spark/spark-1.5.2/spark-1.5.2-bin-hadoop2.6.tgz 上传、解压安装包:

- 1、上传 spark-1.5.2-bin-hadoop2.6.tgz 安装包到 Linux 服务器
- 2、解压安装包到指定位置: tar -zxvf spark-1.5.2-bin-hadoop2.6.tgz -C /usr/local

## 1.3. 修改 Spark 配置文件

- 1、进入 Spark 安装目录: cd /usr/local/spark-1.5.2-bin-hadoop2.6
- 2、进入 conf 目录: cd conf/
- 3、重命名并修改 spark-env.sh.template 文件

mv spark-env.sh.template spark-env.sh

vi spark-env.sh

在该配置文件中添加如下配置

<mark>export JAVA\_HOME=/usr/java/jdk1.7.0\_45 ## :r! echo /usr/java/jdk...用于自动显示</mark> export SPARK\_MASTER\_IP=node1.itcast.cn

export SPARK\_MASTER\_PORT=7077

保存退出

4、重命名并修改 slaves.template 文件

mv slaves.template slaves



#### vi slaves

在该文件中添加子节点(Worker 节点)

node2.itcast.cn

node3.itcast.cn

node4.itcast.cn

保存退出

5、将配置好的 Spark 拷贝到其他节点

scp -r spark-1.5.2-bin-hadoop2.6/ node2.itcast.cn:/usr/local/

scp -r spark-1.5.2-bin-hadoop2.6/ node3.itcast.cn:/usr/local/

scp -r spark-1.5.2-bin-hadoop2.6/ node4.itcast.cn:/usr/local/

6、在 node1.itcast.cn 上启动 Spark 集群

/usr/local/spark-1.5.2-bin-hadoop2.6/sbin/start-all.sh

- 7、启动后执行 jps 命令,主节点上有 Master 进程,其他子节点上有 Worker 进程
- 8、登录 Spark 管理界面查看集群状态: http://node1.itcast.cn:8080

Spork 1.5.2 Spark Master at spark://node1.itcast.cn:7077

URL: spark://node1.itcast.cn:7077
REST URL: spark://node1.itcast.cn:6066 (cluster mode)
Alive Workers: 2
Cores in use: 4 Total, 0 Used

Cores in use: 4 Total, 0 Used
Memory in use: 5.5 GB Total, 0.0 B Used
Applications: 0 Running, 0 Completed
Drivers: 0 Running, 0 Completed
Status: ALIVE

#### Workers

1	Worker Id	Address	State	Cores	Memory
	worker-20151119001811-192.168.10.102-43960	192.168.10.102:43960	ALIVE	2 (0 Used)	2.7 GB (0.0 B Used)
	worker-20151119001811-192.168.10.103-41817	192.168.10.103:41817	ALIVE	2 (0 Used)	2.7 GB (0.0 B Used)

Spark 集群安装完毕。<mark>但是有一个很大的问题:Master 节点存在单点故障。解决此问题需要</mark>借助 zookeeper,并且至少启动两个 Master 节点来实现高可用。

Spark 集群规划: node1, node2 是 Master; node3, node4, node5 是 Worker。

- (1) 安装并启动 zk 集群;
- (2) 停止 spark 服务,修改配置文件 spark-env.sh,在该配置文件中删除 SPARK\_MASTER\_IP、SPARK\_MASTER\_PORT 并添加如下配置:

export SPARK\_DAEMON\_JAVA\_OPTS="-Dspark.deploy.recoveryMode=ZOOKEEPER-Dspark.deploy.zookeeper.url=zk1,zk2,zk3 -Dspark.deploy.zookeeper.dir=/spark" ## Spark向zk写数据的存放目录;

- (3) 修改 slaves 文件内容,指定 worker 节点;
- (4)在 node1 上执行 sbin/start-all.sh 脚本,在 node2 上执行 sbin/start-master.sh 启 动第二个 Master。

# 补充: 搭建 Spark 伪分布式

1、安装 jdk



- 2、解压 spark 压缩包: tar -zxvf spark-1.6.2-bin-hadoop2.6.tgz
- 3、bin 目录下启动 spark-shell: ./spark-shell
  - (1) 启动 spark 单机版应用程序来模拟 spark 集群的运行;
  - (2) spark-shell 是 spark 集群的客户端;若是单机形式,则模拟应用程序在本地执行;
  - (3) spark-shell 启动时创建 SparkContext 对象实例。

```
| Trootening bond | John | Joh
```

#### 注:

- (1) Spark 默认使用 HDFS 的接口读写数据(textFile()、saveAsTextFile())。即使用 InputFormat 读取 key-value 数据,textFile()方法做了处理只保留 value;使用 OutputFormat 写数据。
- (2) Spark 中的算子包括两种:<mark>Transformation</mark> 和 <mark>Action</mark>。<mark>Transformation 延迟加载,触发 Action 时执行。</mark>
- (3) Scala 原生的集合方法操作单机版数据; Spark 提供的 RDD 上的方法并行计算,操作 多台机器上的数据集。
- (4) RDD 是分布式集合,是 Spark 中最基本的抽象。
- (5) reduceByKey()先在一个分区上聚合,再全局聚合。(类似于 combiner 功能)
- (6) 为什么 Spark 的 Transformation 算子延迟加载? 每触发 Transformation 执行一次任务,则需不断地与集群进行交互,所以设计成触发 Action 时提交任务执行。